

# Berkson's Paradoxon

## Teamprojekt

Niman Deskaj

Eberhard Karls Universität Tübingen

26.04.2024

EBERHARD KARLS  
UNIVERSITÄT  
TÜBINGEN



# Inhalte

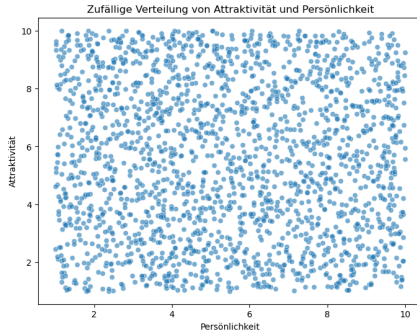
- Motivation
- Definition
- Historischer Hintergrund
- Mathematische Formulierung
- Stichprobenverzerrung meiden
- Fazit



# Motivation

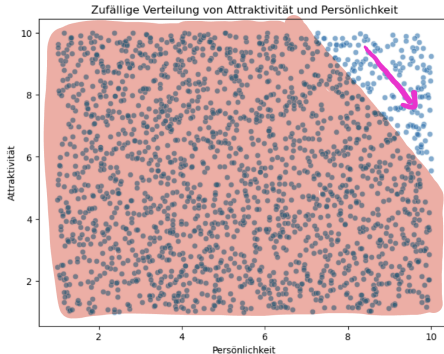
Szenario: Frau möchte Mann daten.

Annahme: Variablen *Persönlichkeit* und *Attraktivität* unabhängig.



- keine unattraktiven und unfreundlichen
- unfreundlich, aber attraktiv, oder freundlich und unattraktiv möglich

# Motivation



Somit ist durch ihre Präferenzen möglich, dass viele der attraktiven weniger freundlich sind und viele der freundlichen weniger attraktiv  
⇒ **negative Korrelation**

# Definition

**Berkson's Paradoxon:** Korrelation zweier (unabhängiger) Größen, zwischen denen kein Kausalzusammenhang besteht, sondern nur eine zufällige oder indirekte Beziehung

- *veridical paradox* (kontraintuitive Einschätzung)
- *selection bias* (Stichprobenverzerrung)



# Historischer Hintergrund

- Joseph Burkson (1946 in *Limitations of the Application of Fourfold Table Analysis to Hospital Data*)
- Fehlinterpretation von statistischen Daten durch fehlerhafte Auswahl von Probanden für Studie
- Risikofaktor: Diabetes, Krankheit: Choleszytitis
- Krankenhauspatienten ohne Diabetes haben viel wahrscheinlicher Choleszytitis, als jemand aus der Bevölkerung, da der Patient aus einem anderen Grund als Diabetes (möglich Choleszytitis-Verursacher) ins Krankenhaus gekommen sein muss  
⇒ **negative Korrelation, ABER kein kausaler Zusammenhang**



# Mathematische Formulierung

Seien  $X$  und  $Y$  zwei unabhängige Variablen, dann gilt:

$$P(X|Y) = P(X)$$

Wir wollen, wie in den Beispielen, dass mind. ein Ereignis auftritt oder beide, aber nicht keins:

$$X \cup Y = X + Y - (X \cap Y)$$

mit  $P(X \cup Y) \leq 1$ . **Für uns**  $P(X \cup Y) < 1$ , **da**  $(\neg X \cap \neg Y)$  **nicht erwünscht**



# Mathematische Formulierung

Wir erhalten

$$P(X) < \frac{P(X)}{P(X \cup Y)}$$

wobei

$$\frac{P(X)}{P(X \cup Y)} = \frac{P(X \cap (X \cup Y))}{P(X \cup Y)} = P(X|X \cup Y)$$

und folglich

$$P(X) < P(X|X \cup Y)$$





# Mathematische Formulierung

Und da

$$P(X) = P(X|Y) = P(X|Y, X \cup Y)$$

gilt

$$P(X|Y, X \cup Y) < P(X|X \cup Y)$$

# Mathematische Formulierung

Was, wenn wir nicht  $(X \text{ or } Y)$  sondern  $(X \text{ and } Y)$  als Auswahlbedingung wollen?

Wir erwarten, dass  $X$  und  $Y$  immer gleichzeitig auftreten also

$$P(X|Y, (X \cap Y)) = P(Y|X, (X \cap Y)) = 1$$

$\Rightarrow$  perfekte positive Korrelation



# Vermeidung von Stichprobenverzerrung

- zufällige Stichprobenmenge
- Umfragen/Studien: auf Gemeinsamkeiten/wenige Unterschiede zwischen Untergruppe und Population achten
- Auf große Stichprobenmengen fokussieren



# Fazit

Wichtige Erinnerung an die Wissenschaft zur gezielten Auswahl der Stichproben und Populationen um ungenaue oder falsche Schlussfolgerungen zu vermeiden!



Vielen Dank für Eure Aufmerksamkeit!

- <https://en.wikipedia.org/wiki/Berkson>
- <https://www.youtube.com/watch?v=0kpFcdKwwwM>
- [https://link.springer.com/chapter/10.1007/978-3-662-64776-9\\_10](https://link.springer.com/chapter/10.1007/978-3-662-64776-9_10)
- <https://towardsdatascience.com/berks-sons-paradox-in-machine-learning-113818ac7657>
- <http://corysimon.github.io/articles/berks-sons-paradox-are-handsome-men-really-jerks/>

